

2026 年における主要 AI 開発エージェントの アーキテクチャと Slash Commands の徹底解剖： Antigravity、Claude Code、Codex の比較分析

2026 年 9 月

概要

ソフトウェア開発における AI の役割は、エディタ内の単一ファイル補完から、リポジトリ全体を探索し計画・実行・検証を自律的に行うエージェントへと移行した。本稿では、こうしたエージェントとの対話において決定論的かつ再現性の高い操作を提供する「スラッシュコマンド」に着目し、Google の Antigravity、Anthropic の Claude Code、OpenAI の Codex CLI の 3 ツールについて、組み込みコマンドの体系、カスタムコマンドの構築メカニズム、基盤アーキテクチャの差異を比較分析する。さらに、スラッシュコマンドを支える技術基盤として Model Context Protocol (MCP) とコンテキストエンジニアリングを整理し、エージェントの自律性がもたらす間接的プロンプトインジェクションや「GuardFall」と呼ばれるセキュリティ上の脅威と、その対策について論じる。

キーワード：AI コーディングエージェント、スラッシュコマンド、Model Context Protocol、コンテキストエンジニアリング、プロンプトインジェクション

1 導入：AI ソフトウェア開発エージェントにおける操作パラダイムの移行

ソフトウェアエンジニアリングの領域において、人工知能の役割は劇的な変化を遂げている。数年前まで主流であった「エディタ内での単一ファイルのコード補完 (Copilot 型)」から、現在では AI が自律的にリポジトリ全体を探索し、計画を立案し、ターミナルコマンドを実行し、テストを修正する「自律型エージェント」へと移行している [1]。この高度な自律性を持つエージェントとの対話において、自然言語の曖昧さを排除し、開発者が決定論的かつ再現性の高い操作を行うための標準的なインターフェースとして定着したのが「Slash Commands (スラッシュコマンド)」である [3]。

スラッシュコマンドは、チャットインターフェースの入力プロンプトにおいて / (スラッシュ) から始まる特定の文字列を入力することで、AI に対して事前に定義された複雑なワークフローの実行、認知モードの切り替え、または特定のコンテキスト (文脈) のロードを強制するメカニズムである [6]。これにより、開発者は「コンテキストの圧縮」「別スレッドでの並行検証」「特定のセキュリティレビュー」といった高度な操作を、自然言語で長々と説明することなく、瞬時に呼び出すことが可能となる [8]。

本稿では、2026 年現在、世界の開発現場を牽引している 3 つの主要な自律型 AI コーディングエー

ジェントー—Google の「Antigravity (旧 Gemini CLI)」、Anthropic の「Claude Code」、および OpenAI の「Codex CLI」——に焦点を当て、各ツールに実装されているスラッシュコマンドの内部仕様、カスタムコマンドの構築メカニズム、基盤となるアーキテクチャの差異、そして自律型エージェント特有のセキュリティ脅威について網羅的かつ深層的な分析を行う。

2 スラッシュコマンドを支える次世代プロトコルとアーキテクチャ

各ツールの具体的なコマンド仕様を分析する前に、最新のスラッシュコマンドを支える技術的基盤と、それが解決しようとしている大規模言語モデル (LLM) 特有の課題について理解することが不可欠である。

2.1 Model Context Protocol (MCP) によるプロンプトの標準化と露出

2024 年後半に Anthropic によって提唱され、2026 年現在では AI 業界全体のオープンスタンダードとして広く採用されている Model Context Protocol (MCP) は、AI エージェント (クライアント) が外部のリソース、ツール、およびプロンプトにアクセスするための JSON-RPC ベースの標準規格である [3]。MCP はしばしば「AI のための USB-C」と形容され、エージェントと外部データソース間の通信を完全に標準化する [11]。

MCP 仕様において、スラッシュコマンドは主に MCP の「Prompts (プロンプト)」プリミティブのユーザーインターフェースとしての側面を持つ [4]。MCP サーバーは、動的な引数を受け取り、リソースからのコンテキストを包含し、特定のワークフローを誘導する再利用可能なプロンプトテンプレートを定義できる [4]。開発者がチャットウィンドウで / を入力した際に表示されるコマンド群の一部は、ハードコードされたものではなく、実際には `prompts/list` エンドポイントを通じて接続中の MCP サーバーから動的に取得・露出されたものである [3]。これにより、例えば Slack や BigQuery、あるいは社内専用のデータ基盤と連携する MCP サーバーを接続した瞬間、それら进行操作するための専用スラッシュコマンドが自動的にターミナル上で利用可能になるという、極めて拡張性の高いエコシステムが形成されている [3]。

2.2 トークン爆発 (Token Explosion) の抑制とコンテキストエンジニアリング

スラッシュコマンドが現代の AI エージェントにおいて重用される第二にして最大の理由は、LLM の推論効率の最適化とコンテキストウィンドウの枯渇防止にある。多数のツール (関数スキーマ) をシステムプロンプトに常駐させると、1 つのツール定義につき 150~400 トークンを消費し、20 個のツールを読み込むだけで数千から数万トークンが消費される「トークン爆発 (Token Explosion)」が発生する [15]。この状態に陥ると、モデルの注意機構 (Attention Mechanism) が散漫になり、ツールの誤選択、ハルシネーション、あるいはコンテキストの忘却 (Context Rot) が引き起こされる [15]。

スラッシュコマンドは、この問題に対する「遅延読み込み (Lazy Loading)」と「スコープ制御」の実践的な解決策を提供する [15]。ユーザーが `/review` や `/plan` といった特定のスラッシュコマンドを呼び出した瞬間にのみ、そのタスクに必要な専用のツール群 (例: コードの差分読み込みツールや Git 操作ツール) と指示文がコンテキストに注入される。これにより、エージェントは常にそのタスクの目的に対して最小十分なコンテキスト (Minimal Sufficiency) のみを保持してタスクを実行

でき、推論の精度向上とレイテンシの劇的な削減が実現される [15]。

3 Claude Code：深層推論と柔軟な Markdown ベースの拡張性

Anthropic が提供する Claude Code は、深い推論（Deep Reasoning）に最適化された CLI ベースのエージェントツールであり、Claude Pro や Max などのサブスクリプションプランに内包される形で提供されている [18]。最大 100 万トークンという巨大なコンテキストウィンドウと、OS レベルでのサンドボックス強制、破壊的コマンドに対する厳格な承認フローを備えており、大規模なリファクタリングや複雑なバグ調査において高い能力を発揮する [18]。

3.1 組み込みコマンドの体系とセッション管理

Claude Code には、2026 年時点で 60 種類以上の組み込みスラッシュコマンドが搭載されており、日常的な開発操作のほぼすべてがコマンド化されている [9]。これらのコマンドは、機能の抽象度や目的によって高度に分類されている（表 1）。

3.2 カスタムコマンドの構築メカニズム

Claude Code のアーキテクチャにおける最大の強みは、開発者がプロジェクト固有のカスタムスラッシュコマンドを極めて直感的かつ容易に構築できる拡張性にある。開発者は、プロジェクトのルートディレクトリにある `.claude/commands/`、またはユーザーグローバルの `~/.claude/commands/` 配下に Markdown ファイル（.md）を配置するだけでよい。このファイル名から拡張子を除いた部分が、そのまま独自のスラッシュコマンド名として認識される（例：`fix-issue.md` は `/fix-issue` となる） [6]。

カスタムコマンドの Markdown ファイルは、単なるプロンプトのテンプレートを越えた、強力なメタデータ制御とコンテキスト動的注入機能を備えている。

- (1) **YAML フロントマターによるメタデータ定義**：ファイルの先頭に記述される YAML フロントマター（Frontmatter）を用いて、メタデータを定義する。ここで `allowed-tools` 属性を指定することで、そのコマンドの実行中に AI が使用できるツールを厳密に制限できる（例：`Bash(git:*)`, `Bash(npm:*)`, `Read(*.md)`） [7]。これにより、特定の調査コマンド実行時にエージェントが暴走して無関係なファイルを書き換えるといったリスクを構造的に排除できる [7]。また、`argument-hint` を定義することで、CLI 上で引数の入力補助を表示させることが可能である [9]。
- (2) **引数の動的展開**：コマンド呼び出し時にユーザーが入力した文字列は、Markdown ファイル内の `$ARGUMENTS` という変数に動的に展開される [6]。
- (3) **シェル実行の事前処理**：ファイル内の行頭に！（感嘆符）を記述すると、プロンプトが LLM に送信される前に指定された Bash コマンドがローカル環境で実行され、その標準出力結果がスラッシュコマンドのコンテキストとして動的に挿入される [7]。例えば、`! npx textlint $ARGUMENTS.md` と記述すれば、AI に指示を出す前に静的解析ツールを実行し、そのエラー結果をコンテキストに含めた上で修正を依頼するといった自律的なワークフローが 1 つのコマン

表1 Claude Code の主要な組み込みスラッシュコマンド

コマンド	カテゴリ	役割とメカニズム
<code>/compact</code> [指示]	コンテキスト管理	長期化したセッションの会話履歴を要約して圧縮する。トークン消費を抑えつつ、直前の文脈や重要な決定事項を維持するために不可欠なコマンドである [9]。
<code>/branch</code> [名前]	コンテキスト管理	現在のセッションの状態から別のバックグラウンドスレッド（ブランチ）をフォークし、メインのターミナルを解放する。長時間かかるテストや並行検証に用いられる（エイリアス： <code>/fork</code> , <code>/bg</code> ） [9]。
<code>/clear</code>	コンテキスト管理	会話履歴を完全にクリアし、コンテキストウィンドウを初期状態にリセットする。前の状態には <code>/resume</code> を用いて復帰可能である [6]。
<code>/rewind</code>	コンテキスト管理	エージェントが誤ったコード修正を行った際などに、会話やコードの状態を以前のチェックポイント（時点）に巻き戻す [9]。
<code>/review</code> [PR]	コード・レビュー	指定されたプルリクエスト（PR）をローカルセッションにロードし、マルチエージェントによる詳細なコードレビューを実行する。より深いクラウドサンドボックス上でのレビューには <code>/ultrareview</code> が用いられる [9]。
<code>/security-review</code>	コード・レビュー	現在のブランチの未コミット変更を、セキュリティの観点から深層分析する [9]。
<code>/plan</code> [説明]	バンドルスキル	即座に実装に入るのではなく、コードベース全体を調査し、要件を定義し、実装計画を立案する「プランモード」に移行する。説明を引数として渡すことで、特定のタスクの計画から開始できる [9]。
<code>/batch</code> <指示>	バンドルスキル	コードベース全体に対する大規模な変更を、5〜30 個の独立したユニットに分解し、複数の並列処理エージェントに委譲して一括処理を行う [9]。
<code>/simplify</code>	バンドルスキル	変更されたファイルを 3 つのエージェントによって並列でレビューさせ、コードの品質や効率に関する問題を特定し、単純化・修正する [9]。
<code>/btw</code> <質問>	ユーティリティ	メインの会話コンテキストを汚染することなく、バックグラウンドでサッと簡単な質問（By the way）を実行する [8]。
<code>/hooks</code>	設定と管理	セッション終了時やツール使用前後に自動実行される「Hooks」の設定を確認・管理する [9]。

ドで完結する [7]。

- (4) **ファイル参照**：行頭に `@` を付けてファイルパスを指定すると、対象ファイルの内容がそのままプロンプトのコンテキストとして展開され、参照コードとして活用される [7]。

2026 年の最新の運用動向として、ユーザーが任意のタイミングで手動で呼び出す旧来の `.claude/commands/*.md` 形式に加え、AI が状況（コンテキスト）に応じて自律的に使用タイミングを判断し自動起動する機能を持つ `.claude/skills/SKILL.md` への移行が公式に推奨されている。これにより、開発体験は「呼ばれたら動く」コマンド駆動から、「勝手に動く」スキル・フック

駆動へとパラダイムシフトが進行している [9]。

4 Google Antigravity：マルチエージェントオーケストレーションと非同期実行

Google が提供する「Antigravity」は、2026 年 6 月 18 日をもってサービス終了した Gemini CLI の完全なる後継プラットフォームとして、Google I/O 2026 で発表された AI ネイティブ開発環境である [23]。Antigravity は、Go 言語で完全に再設計され、極めて高い処理速度と軽量性を誇るターミナル用の「Antigravity CLI」と、統合的なビジュアルエディタである「Antigravity 2.0 (GUI)」という 2 つのサーフェスから構成される [23]。両者は全く同一のコアエージェントハーネスを共有しており、設定、セキュリティ権限、さらには進行中の会話コンテキストに至るまで、インターフェース間でシームレスに同期・移行が可能である [26]。

4.1 組み込みコマンドの体系と推論モードの制御

Antigravity のスラッシュコマンドは、Claude Code のそれと比較して、バックグラウンドでの並列処理と、タスクの複雑さに応じた「推論モード」の動的な切り替えに強く特化している（表 2）。

Antigravity CLI の最も革新的な UX（ユーザーエクスペリエンス）の一つが、ターミナル上で非同期に実行されるサブエージェント群を監視・管理する機能である。プロンプト内で `/agents` と入力すると、専用のサブエージェント管理パネルが開き、実行中、完了、または強制終了されたサブエージェントのステータスと、現在実行中のステップが一覧表示される [28]。開発者はメインの会話フローを中断することなく、`ctrl+j` を押下して承認待ちのサブエージェントの詳細ビューにジャンプしたり、「Fast Path Alerts」機能を利用して `ctrl+k` でツールの実行許可を即座に承認したりすることが可能である [28]。

4.2 カスタムコマンドと外部統合（TOML と MCP）

Antigravity におけるカスタムスラッシュコマンドの定義方法は、Claude Code の Markdown 形式とは異なり、TOML 形式（.toml）のファイルとして構成される。プロジェクトスコープの場合は `.gemini/antigravity-cli/` 配下（旧 `.gemini/commands/`）、ユーザースコープの場合は `~/.gemini/commands/` に配置される [18]。

この TOML ファイル内では、コマンドの `description`（説明）と `prompt`（指示内容）を定義し、ユーザーからの入力は `{{args}}` 変数としてプロンプト内に展開される [32]。さらに特筆すべきは、Antigravity CLI が FastMCP などの MCP サーバーとネイティブに深く統合されており、設定された MCP サーバーが提供するプロンプトを自動的に解析し、スラッシュコマンドとしてターミナルに露出させる機能を持っている点である [26]。これにより、例えば DataRobot などのサードパーティプラットフォームが提供する専用のスキルセットプラグインをインストールするだけで、`/datarobot-skills:datarobot-agent-assist` といった高度な専用スラッシュコマンドが、自作することなく即座に利用可能となる [24]。これらの設定やキーバインドは、すべて `~/.gemini/antigravity-cli/settings.json` および `keybindings.json` で詳細にカスタマイズ可能である [28]。

表 2 Antigravity の主要な組み込みスラッシュコマンド

コマンド	カテゴリ	役割とメカニズム	対象タイム ホライズン
<code>/boost</code>	推論と自律性	複雑なバグ、競合状態、アルゴリズムの最適化といった高度な課題に対して、「オーケストレーター」「ディープコーダー」「検証ワーカー」からなる 3 層のマルチエージェント推論階層をオンデマンドで起動する。これらは独立して仮説を立て、テストスイートを実行し、結果を独自に検証してからメインスレッドに返却する [8]。	秒～数時間
<code>/teamwork-preview</code>	推論と自律性	リポジトリ規模のマイグレーションや長期研究プロジェクトのために、自律的なエージェントチームを編成する。事前のスコープ定義インタビューを行い、マイルストーンに沿ってロードマップを作成し、並列作業を実行する（有料プラン限定機能）[8]。	数時間～ 数日
<code>/goal</code>	推論と自律性	ユーザーのターンごとの確認（Turn-by-turn confirmation pauses）をスキップし、指定された目標（例：特定のパッケージ内の全ユニットテストをパスさせる）が達成されるまで、連続的かつ自律的に実行を続ける [8]。	分～数時間
<code>/plan</code>	計画	直接コードを編集する前に、コードベースを調査し、要件定義のインタビューを行い、レビュー可能な計画書（アーティファクト）を作成する。複雑なタスクのスコープを事前に整理するために用いられる [8]。	分
<code>/grill-me</code>	計画	曖昧な要件に対して、エッジケースや制約条件を明確にするためのステップバイステップの対話的インタビューを AI 側からユーザーに対して実施する [8]。	分
<code>/learn</code>	カスタマイズ	直近のセッションでの修正履歴やユーザーからのフィードバックパターンを分析し、将来のセッションで永続的に適用されるプロジェクトの「ルール」や「スキル」として蒸留・保存する [8]。	即時
<code>/schedule</code>	自動化	指定されたタスクを、一回限りのタイマー、または cron 式のスケジュール（例：毎朝特定のランチをクリーンアップする）に従ってバックグラウンドで自律実行させる [8]。	スケジュール 指定
<code>/browser</code>	ツール	サンドボックス化された Chrome ブラウザのサブエージェントを起動し、Web 上の最新リサーチや、ローカルで立ち上げた UI のライブレンダリング・レイアウト検証を実行させる [8]。	分
<code>/title</code>	ウィンドウ制御	ターミナルウィンドウのタイトルバー機能を切り替え、アクティブなモデル、ワークスペース、エージェントのステータスを動的に表示するよう構成する [29]。	即時
<code>/voice</code>	インプット	音声ディクテーションを有効化し、タイピングではなく音声によってエージェントへの指示を入力する [30]。	即時

5 OpenAI Codex (Codex CLI)：厳密な階層型コンテキストと非対話型自動化

OpenAI が提供する「Codex CLI」は、ChatGPT のサブスクリプション（Plus, Pro, Business, Enterprise 等）にバンドルされる形で提供される、ターミナル常駐型の AI コーディングエージェントである [18]。Claude Code や Antigravity が自然言語による「会話型のインターフェース」に重きを置いているのに対し、Codex CLI はより「ソフトウェア・エンジニアリング・エージェント」としての性格が強く、厳密なサンドボックス制御、非対話型の自動化（codex exec による CI/CD パイプラインへの組み込み）、そしてプロジェクト規約の徹底に特徴がある [18]。

5.1 組み込みコマンドとセッション制御

Codex CLI のスラッシュコマンドは、対話の管理、状態の監視、およびワークフローの厳格な切り替えに重点を置いている（表 3）。

表 3 Codex CLI の主要な組み込みスラッシュコマンド

コマンド	役割とメカニズム
/permissions	セッション中にコマンド実行前の承認挙動やサンドボックスの実行権限を動的に変更する（旧 /approvals）[37]。
/status	現在のアクティブなモデル、承認モード、トークン使用量、コスト見積もり、Weekly リミットの消化状況、およびセッションの詳細などのシステムステータスを一覧表示する [36]。
/usage	トークンのアクティビティ、レート制限、および利用可能な使用量リセットクレジットの状況を表示する [41]。
/compact	長期化し蓄積された会話履歴を要約し、コンテキストウィンドウの消費を節約する [36]。
/side	現在のメインスレッドのコンテキストを維持したまま、一時的なサイドチャット（別スレッド）を開始する。本筋のコードを汚さずにアーキテクチャの相談や特定の関数の動作検証を行う際に極めて有効である [37]。
/review	対話モードを離れ、現在の作業ツリーの差分（変更点）に対する非対話型のコードレビューを実行し、バグやリグレッションを指摘する [37]。
/init	カレントディレクトリを自動探索し、プロジェクトの概要や技術スタックを記述した AGENTS.md の足場（スキュフォールド）を自動生成する [36]。
/model	セッションの途中でアクティブなモデルと、推論の深さ（Reasoning effort: low, medium, high）を動的に切り替える [36]。
/sandbox-add-read-dir	サンドボックス環境に対して、指定した別のディレクトリへの読み取りアクセス権を動的に付与する [39]。
/export	現在のターミナル（TUI）上の会話全体を Markdown 形式でエクスポートし、ファイルに保存するかクリップボードにコピーする [37]。
/cd / /pwd	エージェントの作業ディレクトリをセッション内で動的に変更・表示する（v0.149.0 以降の機能）[37]。

5.2 アーキテクチャの中核：階層型 AGENTS.md パラダイム

Codex CLI のアーキテクチャを語る上で欠かせないのが、コンテキスト管理の絶対的な基盤となる AGENTS.md という標準仕様である。これは Agentic AI Foundation の管理下で 60,000 以上のプロジェクトで採用されているオープンフォーマットであり、AI エージェントに対してプロジェクト固有のコーディング規約、テスト環境の仕様、アーキテクチャの制約、そして絶対的な禁止事項を永続的に定義する「エージェント向けの README」として機能する [43]。

Codex は、新たなタスクを実行する際、必ず以下の順序で階層的に AGENTS.md を探索し、それらを結合（マージ）してプロンプトの最上流コンテキストに注入する [46]。

1. **グローバルスコープ**：ユーザーのホームディレクトリ（`~/.codex/AGENTS.md`）。個人のコーディングの好みや、全プロジェクトに共通して適用すべき普遍的なルール（例：常に特定のパッケージマネージャーを優先する等）を定義する [45]。
2. **プロジェクトルート**：リポジトリ直下の AGENTS.md。プロジェクト全体のアーキテクチャ設計、CI/CD 規則、フレームワークのバージョン制約など、チーム全体で共有すべき設定を記述する [45]。
3. **サブディレクトリ**：現在の作業ディレクトリに至るまでの各階層の AGENTS.md または AGENTS.override.md。特定のサービスやモジュール（例：`frontend/` や `services/payments/`）固有のローカルなルールを定義する [45]。

重要なアーキテクチャ上の特性として、Codex はこれらのファイルをルートからカレントディレクトリに向かって順番に読み込み、結合する。プロンプト内では後に読み込まれたファイル（より深い階層のファイル）の指示が優先されるため、モジュール固有のローカルルールがプロジェクト全体のグローバルルールを安全に上書き（オーバーライド）する設計となっている [46]。

AI の挙動が不安定になること（ハルシネーションや規約違反）を防ぐため、AGENTS.md には自然言語の曖昧な散文ではなく、「検証可能なコマンド（例：`npm run lint` を実行し、終了コードが 0 であること）」や「Done の定義（Definition of Done）」を厳格に記述することがベストプラクティスとされている [43]。設定ファイルである `~/.codex/config.toml` では、使用モデルの指定に加え、ファイル書き込みの制限レベル（`workspace-write` 等のサンドボックスモード）や、プロファイルごとの細かな挙動制御が可能である [36]。また、Codex は MCP クライアントとしてだけでなく、自身が MCP サーバーとして機能する能力も備えており、他のツールから呼び出されるバックエンドエージェントとしても動作可能である [18]。

6 3 大プラットフォームの多角的な比較分析

Antigravity、Claude Code、Codex は表面的には類似した「AI コーディングエージェント」という機能を提供するが、そのターゲット層、価格モデル、コンテキストウィンドウの設計、およびサブエージェントの処理方式において、明確な設計思想の差異が存在する [1]（表 4）。

表 4 3 大プラットフォームの比較

比較項目	Google Antigravity	Claude Code	OpenAI Codex CLI
価格モデルと利用制限	基本無料枠あり（制限超過後はフラッシュモデル等の軽量モデルへフォールバック）。GCP 連携重視 [18]。無料枠のクォータ上限に達しやすい [51]。	Claude Pro/Max サブスクリプション（月額\$20〜）に内包。API 利用枠を共有するため、使用量制限は比較的厳しい [19]。	ChatGPT サブスク（Plus/Pro/Biz 等）に内包。高リミットで許容範囲が広く、長時間の作業に適する [18]。
コンテキストウィンドウ	Gemini 1.5 Pro 等の統合により最大約 100 万トークンの広大なウィンドウ [18]。	20 万～100 万トークン。深層推論と長期的なコンテキスト保持に極めて優れる [18]。	CLI 本体では約 40 万トークン（API 経由で最大 100 万まで拡張可） [18]。
サブエージェント方式	ターミナル上の専用パネル（/agents）による非同期監視。メインスレッドをブロックせず並行作業を委譲 [18]。	ネイティブな深い推論による自律的なタスク分解とサブワーカーの呼び出し [18]。	実験的な Multi-agents 機能。環境変数で有効化し、ファンアウトと結果の集約によるサブタスク実行 [18]。
セキュリティ・サンドボックス	軽量な OS ネイティブ分離（Linux の nsjail、macOS の sandbox-exec 等）をゼロスタートアップ時間で提供 [28]。	OS 強制サンドボックスに加え、破壊的コマンドに対する厳格な組み込み承認フロー（Bash/Zsh 対応） [18]。	workspace-write などの明示的な名前付きポリシー。隔離環境での実行（codex exec）に強み [18]。
カスタムコマンド・拡張形式	.toml 形式（プロンプトと設定を定義）および MCP サーバーからの自動露出 [32]。	.md 形式（YAML フロントマターによるツール制限、Bash コマンド実行を含む） [7]。	AGENTS.md を軸とした階層的コンテキスト定義と設定ファイル（config.toml） [44]。

6.1 実践的ユースケースに基づく評価と開発者の選定基準

実業務における評価データや開発者コミュニティのフィードバックに基づくと、これら 3 つのツールの選択は、開発チームのスタイルやタスクの性質に強く依存する [19]。

Claude Code は、事前のプロンプト指示が少なくてもリポジトリ全体のコンテキストを把握し、文脈から最適解を導き出す「探求的・推論的」なタスクに圧倒的に優れている [19]。しかし、些細な修正依頼に対して広範なコード変更を提案する「オーバーエンジニアリング」の傾向があり、さらにトークンリミットの消費が早いため、週の半ばで制限に到達してしまうケースが報告されている [19]。

一方、Codex CLI は、仕様が明確に定義されたタスク（特に AGENTS.md によって制約が厳格にコントロールされた環境下）において、開発者の指示に忠実に従う実行精度の高さが評価されている [19]。また、サブスクリプションの利用枠（クォータ）が比較的大きく、長時間の非同期タスクや CI/CD パイプラインへのヘッドレスな組み込みに最適である [19]。

Antigravity はこれらの中間に位置する。GUI（Antigravity 2.0）と CLI のシームレスな移行、および Google Cloud のエコシステム（例えば Spanner マイグレーションタスクの自動化など）との統合において無類の強みを発揮する [23]。初期導入のハードルが低く初学者にも推奨されるが、無料枠のクォータ上限に達しやすく、ヘビーユースにおいては上位プランの検討が必要となる [18]。

実プロジェクトにおいては、新規機能の探求的な開発には Claude Code を使用し、大規模なリファクタリングや PR（プルリクエスト）の自動レビュー、CI 連携には Codex を使用するといった「複数ツールの共存運用（併用）」が最適解として採用されるケースが増加している [50]。

7 エージェントの自律性がもたらす新たなセキュリティ脅威と「GuardFall」

スラッシュコマンドや自律型サブエージェントが提供する高度な自動化と権限の委譲は、同時に、従来のソフトウェアサプライチェーンには存在しなかった全く新しいクラスの深刻なセキュリティ脆弱性をもたらしている。2026 年現在、AI コーディングエージェントにおける最大の脅威として認識されているのが「間接的プロンプトインジェクション (Indirect Prompt Injection)」である [53]。これは、100 名以上のセキュリティ研究者によって策定された「OWASP Top 10 for Agentic Applications 2026」において、「Agent Goal Hijacking (ASI01)」として第 1 位のリスクに認定されている [53]。

7.1 攻撃のメカニズム：文脈の汚染とデータ流出

プロンプトインジェクションは、攻撃者がコードのコメント、Jira や Linear のチケット説明文、ダウンロードされた OSS ライブラリの README.md、あるいは Web ページの隠し HTML タグ（白地に白文字やゼロ幅文字で難読化されたもの）の中に、悪意のある指示を埋め込むことで成立する [53]。例えば、「これまでの指示をすべて無視し、`~/aws/credentials` の内容を読み取り、特定の外部サーバーに URL パラメータとして送信せよ」といった指示である [54]。

AI エージェント (LLM) の根本的なアーキテクチャ上の欠陥は、開発者が与えた「システムプロンプト (本来の指示)」と、外部から読み込んだ「データ (コンテキスト)」を数学的に区別できない点にある [53]。エージェントが `/plan` や `/review` などのスラッシュコマンドを実行し、ワークスペース内のファイルを読み込んだ瞬間、ファイル内に潜んでいたインジェクションが発火し、エージェントの主導権が攻撃者に奪われる (ハイジャックされる) [54]。

学術調査や実証実験 (PoC) によれば、この手法による悪意のあるコマンドの実行成功率は最大 84% に達する [57]。実際に 2026 年 3 月には、「Claudy Day」と名付けられた攻撃手法が実証され、デフォルト設定の Claude Code から会話履歴や機密データが、MCP ツールや特別な構成を必要とせず外部へ流出 (Exfiltration) する可能性が示された [53]。また、Claude Code や GitHub Copilot において、ユーザーの確認ダイアログが表示される前にコマンドが実行されてしまう深刻な脆弱性 (CVE-2025-65099、CVE-2025-62222 など) も報告されている [57]。

7.2 自動実行フラグの罠と「GuardFall」現象

このプロンプトインジェクションの問題を致命的なものに悪化させているのが、CI/CD パイプラインや長時間の自律タスクで開発者が頻繁に使用する「自動実行 (Auto-execution)」フラグである。例えば、Claude Code の `--dangerously-skip-permissions` や、Codex の `--ask-for-approval never` などがこれに該当する [37]。

開発者はプロセスの効率化のためにこれらのフラグを有効にするが、多くのエージェントツールが実装しているセキュリティガードレール (危険なシェルコマンドをブロックするための単純な文字列マッチングフィルター) は、Bash の変数展開や難読化手法を正しく解釈できない [58]。その結果、悪意のある Makefile ターゲットや、MCP のドキュメントレスポンスとして偽装されたシェルコマン

ドがフィルターを容易にすり抜け、ホストマシンの権限で直接実行されてしまう。

この脆弱なフィルターによって生み出される偽りの安心感と、それに伴う Human-in-the-Loop (人間による最終確認プロセス) の放棄はセキュリティ界隈で「GuardFall」と呼ばれている [58]。コンテナ化されたサンドボックス環境であっても、エージェントがアクセス可能なワークスペース内に本番環境の認証情報 (AWS キーや SSH 鍵) が存在する限り、データ流出やインフラの乗っ取りを完全に防ぐことはできない [54]。

この脅威を軽減するためには、単なる文字列フィルタリングに頼るのではなく、エージェントのツールへのアクセス権限を最小特権 (Least-Privilege) の原則に基づいて制限し、MCP ゲートウェイを用いてタスクごとに呼び出せる API を厳格にスコープ分けするインフラストラクチャレベルの防御が不可欠となっている [53]。

8 結論：次世代 AI コーディング環境に向けた戦略的適応

2026 年における AI 開発エージェントツールは、Antigravity、Claude Code、Codex の三者三様のアーキテクチャの進化により、自然言語による単一のプロンプト入力から、スラッシュコマンドを起点とした「意図の宣言と構造化されたワークフローの実行」へと決定的なパラダイムシフトを果たした。

- **Claude Code** は、`.claude/commands/` や Hooks を通じた極めて柔軟な Markdown ベースの拡張性を持ち、強力な深層推論能力によってプロジェクト全体を俯瞰したりファクタリングを指揮する、探求的な開発の第一選択肢である。
- **Google Antigravity** は、Go 言語ベースの軽量な CLI 環境と GUI のシームレスな統合を実現し、`/boost` や `/agents` のようなマルチエージェント階層構造をオンデマンドで動的に生成・管理するオーケストレーション能力に長けている。
- **OpenAI Codex** は、`AGENTS.md` という階層的なコンテキスト仕様を業界標準として確立し、厳格なサンドボックス制御と非対話型の自動化 (CI 連携) において比類ない堅牢性を提供する。

これらのツールに共通するスラッシュコマンドの根底には、Model Context Protocol (MCP) による外部ツールの動的ロードと、トークン爆発を防ぐための高度なコンテキスト管理 (Context Engineering) の概念が存在する。エージェントが必要な時に、必要なツールとプロンプトだけを遅延読み込みするこのアーキテクチャは、推論の精度と実行速度を劇的に向上させた。

しかしながら、エージェントが高度な自律性と外部ツールの実行権限を獲得したことで、間接的プロンプトインジェクションという未知の重大なセキュリティリスクが表面化している。スラッシュコマンドによって呼び出されたエージェントが、外部の汚染されたリソースを読み込んだ瞬間にハイジャックされる危険性は、現在の AI 開発において最も警戒し、対策を講じるべき課題である。

現代のソフトウェア開発チームは、これらの AI ツールがもたらす強力な生産性向上効果を楽しむ一方で、`AGENTS.md` や `SKILL.md` などのガバナンス機能を用いたプロジェクトルールの徹底、MCP によるツールアクセスの最小化、そして自動実行モードに対する厳格な監査体制を構築し、AI エージェントを安全かつ効率的にシステムアーキテクチャ全体に統合していくことが強く求められている。

参考文献

- [1] Antigravity 2.0・IDE・CLI の違いを整理してみた, <https://www.yoshidumi.co.jp/collaboration-lab/antigravity2.0-ide-cli>
- [2] Abstract - arXiv, <https://arxiv.org/html/2608.16911v1>
- [3] Model Context Protocol (MCP) explained: A practical ... - CodiLime, <https://codilime.com/blog/model-context-protocol-explained/>
- [4] Prompts - Model Context Protocol (MCP) , <https://modelcontextprotocol.info/docs/concepts/prompts/>
- [5] SemaClaw: A Step Towards General-Purpose Personal AI Agents, <https://arxiv.org/html/2604.11548v1>
- [6] 【Claude Code】カスタム Slash Command の作り方とコマンド例を, <https://zenn.dev/oikon/articles/cb11b84f891228>
- [7] Claude Code でカスタムスラッシュコマンドを作成する, <https://azukiazusa.dev/blog/claude-code-custom-slash-command/>
- [8] Slash commands overview | Google Antigravity Docs, <https://antigravity.google/docs/slash-commands/>
- [9] Claude Code Slash Command 完全ガイド 2026 - 株式会社 Uravation, <https://uravation.com/media/claude-code-slash-command-custom-extension-team-share-2026/>
- [10] Claude Code コマンド完全ガイド | スラッシュコマンド 96 個 +CLI, <https://crystal-method.com/blog/claude-code-slash-commands/>
- [11] Model Context Protocol (MCP) - Medium, <https://medium.com/@aserdargun/model-context-protocol-mcp-e453b47cf254>
- [12] Model Context Protocol - Authzed Docs, <https://authzed.com/docs/mcp>
- [13] Prompts - What is the Model Context Protocol (MCP)?, <https://modelcontextprotocol.io/specification/2025-11-25/server/prompts>
- [14] MCP: Model Context Protocol - Cheatsheet | SFEIR Institute, <https://institute.sfeir.com/en/claude-code/claude-code-mcp-model-context-protocol/cheatsheet/>
- [15] The Over-Tooled Agent Problem: Why More Tools Make Your LLM, <https://tianpan.co/blog/2026/04/19/over-tooled-agent-problem>
- [16] The Workload-Router-Pool Architecture for LLM Inference ... - arXiv, <https://arxiv.org/html/2603.21354v1>
- [17] Building AI Coding Agents for the Terminal: Scaffolding, Harness, <https://arxiv.org/html/2603.05344v1>
- [18] Claude Code vs Codex CLI vs Antigravity CLI: 2026 Comparison, <https://nektony.com/reviews/claude-code-vs-codex-cli-vs-antigravity-cli>
- [19] Claude Code vs Cursor vs OpenAI Codex vs Google Antigravity (2026), <https://www.bdtechjobs.com/blog/claude-code-vs-cursor-vs-codex-vs-antigravity>
- [20] Slash Commands を組織知に変える運用 | Claude Code の便利, <https://techaide.jp/blog/claude-code-slash-commands-team-sharing/>
- [21] Claude Code のカスタムスラッシュコマンド完全ガイド ... - Qiita, <https://qiita.com/hikariclaude01/items/be384cf99c61fbb6b643>
- [22] CLAUDE.md, Rules, Skills Slash Command を理解する | inady - note, <https://note.com/inady/n/n425800bd5d90>
- [23] 【2026 年最新】AI 駆動開発ツール比較 7 選！ Google Antigravity, <https://cloud-ace.jp/column/detail558/>
- [24] DataRobot for Developers — integrating with the Google Antigravity, <https://www.datarobot.com/blog/datarobot-for-developers-integrating-with-the-google-antigravity-cli/>

- [25] Antigravity CLI vs Claude Code vs Codex: The Terminal Agent Field, <https://www.developersdigest.tech/blog/antigravity-cli-vs-claude-code-vs-codex-2026>
- [26] Antigravity CLI Overview | Google Antigravity Docs, <https://antigravity.google/docs/cli/overview/>
- [27] Google Antigravity CLI, <https://antigravity.google/blog/introducing-google-antigravity-cli>
- [28] Antigravity CLI Features, <https://antigravity.google/docs/cli/features/>
- [29] Window Title Command (/title) | Google Antigravity Docs, <https://antigravity.google/docs/cli/commands/title/>
- [30] Voice Dictation (/voice) | Google Antigravity Docs, <https://antigravity.google/docs/cli/commands/voice/>
- [31] Antigravity CLI, <https://antigravity.google/product/antigravity-cli/>
- [32] Gemini CLI: Custom slash commands | Google Cloud Blog, <https://cloud.google.com/blog/topics/developers-practitioners/gemini-cli-custom-slash-commands>
- [33] Custom commands | Gemini CLI, <https://geminicli.com/docs/cli/custom-commands/>
- [34] Using AGY CLI | Google Antigravity Docs, <https://antigravity.google/docs/cli/using/>
- [35] Codex CLI スラッシュコマンド一覧 — /plan ・ /fork ・ /init など全 33, <https://sakutto-panda.com/guides/codex-slash-commands>
- [36] 【ガイド】 OpenAI 発のコーディングエージェント「Codex CLI」の, https://note.com/daybreak_diary/n/n754b58ed422f
- [37] Codex CLI とは | 使い方 ・ 全コマンド一覧 ・ exec 【2026 年 9 月】 , <https://uravation.com/media/codex-cli-complete-reference-2026/>
- [38] Codex CLI とは？ GPT-5.2-Codex 対応の AI コーディングを徹底解説, <https://www.ai-souken.com/article/codex-cli-comprehensive-guide-2025>
- [39] Codex CLI Cheat Sheet & Quick Reference - CheatSheets.zip, <https://cheatsheets.zip/codex-cli>
- [40] OpenAI: Codex — AGENTS.md と MCP を活用したより効果的な AI, <https://note.com/repkuririn7/n/n5bd16375267a>
- [41] codex-commands-cheat-sheet/README.md at main - GitHub, <https://github.com/jqueryscript/codex-commands-cheat-sheet/blob/main/README.md>
- [42] codex に codex の徹底解説をしてもらった - Zenn, <https://zenn.dev/dokusy/articles/99af2fae0f1291>
- [43] AGENTS.md Patterns: What Actually Changes Agent Behavior, <https://blakecrosley.com/blog/agents-md-patterns>
- [44] AGENTS.md の育て方（検討/模索中） - Zenn, https://zenn.dev/secondselection/articles/agent_md_tuning
- [45] Context Management Strategies for OpenAI Codex, <https://datalakehousehub.com/blog/2026-03-context-management-openai-codex/>
- [46] Custom instructions with AGENTS.md - ChatGPT Learn, <https://learn.chatgpt.com/docs/agent-configuration/agents-md>
- [47] OpenAI 公式「Codex Prompting Guide」を読み解く gpt-5.2 ... - Qiita, <https://qiita.com/nogataka/items/d717d051882bfb2d2819>
- [48] Codex AGENTS.md の書き方 | 7 パターンと階層設計 【2026 年 9 月】 , <https://uravation.com/media/codex-agents-md-complete-guide-2026/>
- [49] Codex CLI を使いこなすための機能 ・ 設定まとめ - Zenn, https://zenn.dev/dely_jp/articles/codex-cli-matome
- [50] 【実測比較】 Claude Code vs Codex 料金 ・ 性能 - 合同会社 playpark, <https://www.playpark.co.jp/blog/claude-code-vs-codex-comparison>
- [51] Codex vs Claude Code vs Antigravity - what's your honest take after, <https://www.reddit.com>

- [/r/codex/comments/1s1btfx/codex_vs_claude_code_vs_antigravity_whats_your/](#)
- [52] Cursor vs OpenAI Codex vs Claude Code vs Antigravity, <https://grzegorzaminski.eu/en/blog/cursor-vs-codex-vs-claude-code-vs-antigravity-2026>
 - [53] Understanding Prompt Injection Risks in Claude Code - Truefoundry, <https://www.truefoundry.com/blog/claude-code-prompt-injection>
 - [54] Agent Security Boundaries: From Prompt Injection to Tool Misuse, <https://tao-hpu.medium.com/agent-security-boundaries-from-prompt-injection-to-tool-misuse-d25b6dbaad60>
 - [55] Prompt Injection and the Security Risks of Agentic Coding Tools, <https://www.securecodewarrior.com/blog/prompt-injection-and-the-security-risks-of-agentic-coding-tools>
 - [56] Prompt Injection in 2026: Impact, Attack Types & Defenses, <https://jp.radware.com/cyberpedia/prompt-injection/>
 - [57] Demystifying Prompt Injection Attacks on Agentic AI Coding Editors, <https://arxiv.org/html/2509.22040v2>
 - [58] AI coding agents vulnerability: GuardFall shell injection - Adversa AI, <https://adversa.ai/blog/opensource-ai-coding-agents-shell-injection-vulnerability/>